Mazelan 詳細設計書

最終更新: 2026-03-20

---

1. バックエンド詳細設計

1.1 ファイル構成

```
backend/
├── main.py              # FastAPI アプリ初期化、ミドルウェア、例外ハンドラ
├── database.py          # SQLAlchemy エンジン、セッション管理
├── models.py            # ORM モデル（User, ChatSession, Message, Context）
├── schemas.py           # Pydantic バリデーション（画像）
├── dependencies.py      # JWT 認証依存（NextAuth JWT）
├── providers.py         # マルチプロバイダー LLM 抽象化
├── base_prompt.py       # システムプロンプトテンプレート
├── context_extractor.py # コンテキスト自動抽出（Claude Haiku）
├── amazon_search.py     # Amazon 商品検索（SerpAPI）
├── flight_search.py     # フライト検索（SerpAPI + Travelpayouts）
├── serpapi_cache.py     # SerpAPI インメモリ TTL キャッシュ
├── seed_user.py         # ユーザー作成 CLI ユーティリティ
└── routers/
    ├── auth.py          # 認証エンドポイント
    ├── chat.py          # チャットストリーミング
    ├── debate.py        # ディベートモード
    ├── sessions.py      # セッション CRUD
    └── contexts.py      # コンテキストメモリ CRUD
```

1.2 マルチプロバイダーアーキテクチャ（providers.py）

1.2.1 MODEL_REGISTRY

全モデルを統一的に管理する辞書。各エントリは以下のフィールドを持つ:

```
{
    "model_id": {
        "provider": "anthropic" | "openai" | "google",
        "label": "表示名",
        "input_price": float,   # $/M tokens
        "output_price": float,  # $/M tokens
        "supports_images": bool,
        "supports_thinking": bool,
    }
}
```

1.2.2 プロバイダー別ストリーミング関数

プロバイダー	関数	特記事項
Anthropic	`stream_anthropic()`	web_search 組み込み対応、thinking ブロック対応
OpenAI	`stream_openai()`	o-series は `max_completion_tokens` 使用、画像は data URI 形式
Google	`stream_google()`	`google_search` と `function_calling` は同一リクエストで併用不可 → 動的切替

1.2.3 メッセージフォーマット変換

Anthropic → OpenAI 変換:

- `image` ブロック → `image_url` (data URI) に変換
- `system` メッセージ → メッセージ配列の先頭に移動
- o3-mini は画像非対応のため自動除去

Anthropic → Gemini 変換:

- `Content` / `Part` 型に変換
- 連続する同一 role メッセージを自動マージ（Gemini の制約）
- `inline_data` 形式で画像を渡す

1.2.4 ツール実行ループ

```
ユーザーメッセージ送信
  ↓
AI がツール呼び出しを返す（tool_use）
  ↓
ツール実行（amazon_search / flight_search）
  ↓
結果を AI に返す（tool_result）
  ↓
AI が最終回答を生成（最大3ラウンド）
```

- Anthropic: `tool_use` / `tool_result` コンテンツブロック
- OpenAI: `function_calling` / `tool_calls` 形式
- Gemini: `FunctionDeclaration` / `FunctionResponse` 形式
- ディベートモードではツール無効化（`disable_tools=True`）

1.2.5 Gemini フリーキープール

```
ユーザーキーあり → ユーザーキーで実行
  ↓（未設定）
Flash Lite かつ GEMINI_FREE_KEYS 設定あり → プールからローテーション
  ↓（クォータエラー）
X-Google-Fallback-Key ヘッダーあり → フォールバックキーで実行
  ↓（未設定）
エラー返却
```

1.2.6 拡張思考（Extended Thinking）

プロバイダー	設定	トークン予算
Anthropic	`thinking={"type": "enabled", "budget_tokens": 10000}`	10,000
OpenAI (o-series)	`max_completion_tokens` 自動使用	-
Gemini	`ThinkingConfig(thinking_budget=10000)`	10,000

1.3 チャットストリーミング処理フロー（chat.py）

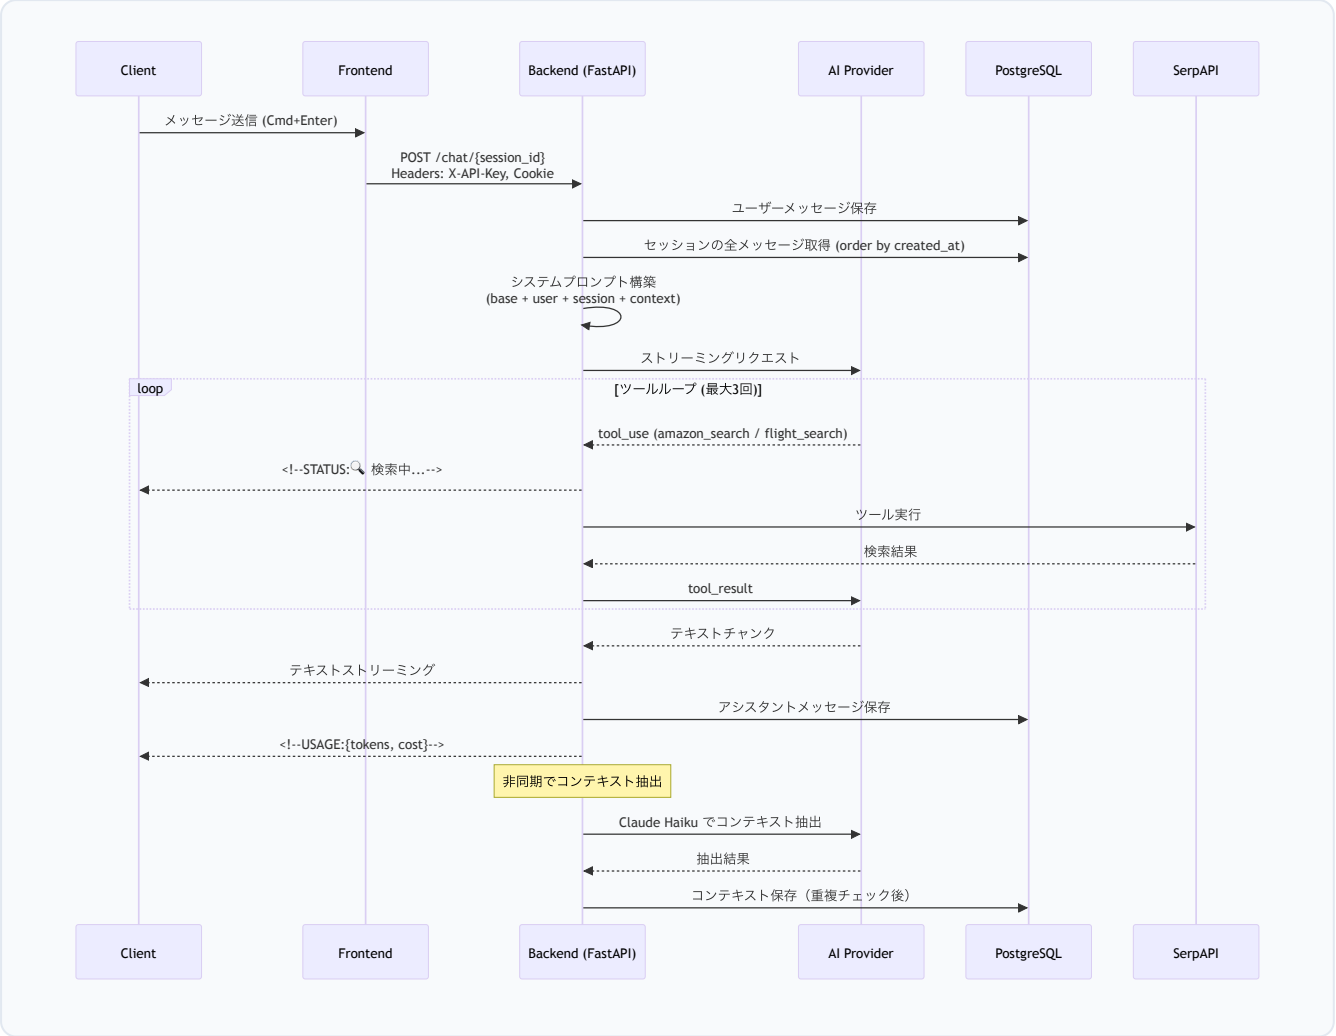

1.4 ディベートモード処理フロー（debate.py）

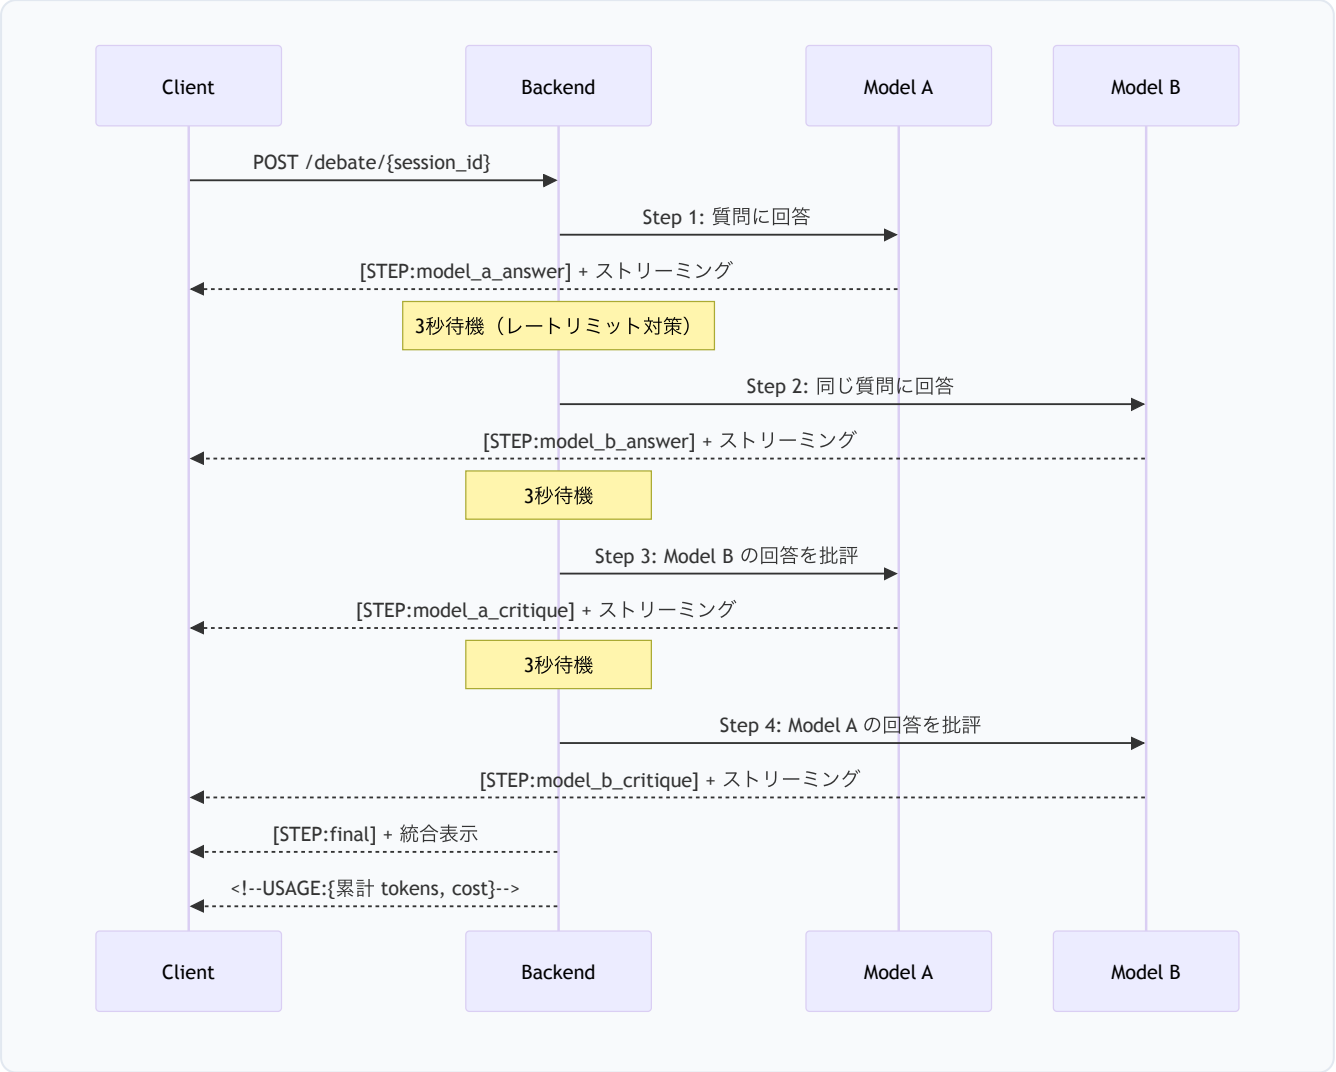

1.5 コンテキスト抽出フロー（context_extractor.py）

```
チャット応答完了
  ↓（非同期・fire-and-forget）
ユーザーメッセージを2000文字に切り詰め
  ↓
Claude Haiku に抽出依頼（ユーザーの言語で）
  ↓
JSON 配列で返却: [{content, category}]
  ↓
各エントリに対して:
  - 既存コンテキストと双方向部分文字列比較
  - 重複なし → DB に保存
  - 重複あり → スキップ
```

1.6 フライト検索アルゴリズム（flight_search.py）

```
入力: origin, destination, departure_month, day_from, day_to, trip_weeks
  ↓
Step 1: day_from〜day_to から3つの候補日を均等に生成
  ↓
Step 2: 各候補日で片道検索（並列） → 最安2日程を選定
  ↓
Step 3: 各安い出発日に対し、3つの帰国日候補を検索（並列）
        → 最安の帰国日を特定
  ↓
Step 4: 上位2組の日程で往復詳細検索（並列）
  ↓
Step 5: スコアリング（price×1.0 + duration×50 + stops×10000）
        → 上位結果 + 最安フライトを返却
```

SerpAPI 消費量: 最大 ~11回/検索（キャッシュヒット時は0回） **キャッシュ TTL**: フライト 3時間、Amazon 1時間

1.7 システムプロンプト階層

```
1. base_prompt（旅行コンシェルジュ基本指示 + ツールガイダンス）
   ↓ 結合
2. ユーザーグローバルプロンプト（users.system_prompt）
   ↓ 上書き/追加
3. セッション固有プロンプト（chat_sessions.system_prompt）
   ↓ 追加
4. コンテキストメモリブロック（<context_memory>タグ）
```

1.8 エラーハンドリング

プロバイダー例外クラス

例外	表示	原因
`ProviderAuthError`	🔑 API キーエラー	無効/未設定のキー
`ProviderRateLimitError`	⏱️ レートリミット	429 レスポンス
`ProviderSpendLimitError`	💳 月間上限超過	課金上限到達
`ProviderError`	⚠️ 汎用エラー	その他のエラー

Gemini リトライ戦略

- 対象: 429、503、UNAVAILABLE、RESOURCE_EXHAUSTED
- 方式: 指数バックオフ（2^attempt 秒）
- 最大リトライ: 3回

1.9 レートリミット設定

エンドポイント	制限
`/auth/register`	3/min
`/auth/login`	5/min
`/auth/upsert-user`	10/min
`/chat/*`	20/min
`/debate/*`	10/min
`/sessions` (CRUD)	30/min
`/sessions/*/delete`	20/min
`/sessions/*/system-prompt`	10/min
`/contexts/*`	20/min

2. フロントエンド詳細設計

2.1 ファイル構成

```
frontend/
├── app/
│   ├── layout.tsx           # ルートレイアウト（i18n + Providers）
│   ├── providers.tsx        # SessionProvider + ThemeProvider
│   ├── page.tsx             # / → /chat リダイレクト
│   ├── chat/page.tsx        # メインチャットページ（状態管理の中心）
│   ├── login/page.tsx       # ログインページ
│   ├── terms/page.tsx       # 利用規約
│   ├── privacy/page.tsx     # プライバシーポリシー
│   └── api/auth/[...nextauth]/route.ts  # NextAuth ハンドラ
├── components/
│   ├── Sidebar.tsx          # セッション一覧、設定、テーマ切替
│   ├── ChatInput.tsx        # メッセージ入力、画像添付、モデル選択
│   ├── QAPairBlock.tsx      # 折りたたみ Q&A ペア表示
│   ├── MessageContent.tsx   # Markdown レンダリング
│   ├── ApiKeyModal.tsx      # API キー管理モーダル
│   ├── SystemPromptModal.tsx # システムプロンプト設定
│   ├── ContextModal.tsx     # コンテキストメモリ管理
│   ├── DebateDisplay.tsx    # ディベート表示
│   ├── ProviderIcon.tsx     # プロバイダーアイコン SVG
│   └── TokenUsageTooltip.tsx # トークン使用量ツールチップ
├── lib/
│   ├── api.ts               # バックエンド API クライアント
│   ├── types.ts             # TypeScript 型定義
│   ├── apiKeyStore.ts       # localStorage API キー管理
│   ├── themeContext.tsx      # テーマ Context
│   └── exportChat.ts        # チャットエクスポート
├── i18n/
│   └── request.ts           # next-intl サーバー設定
├── messages/
│   ├── en.json              # 英語翻訳
│   └── ja.json              # 日本語翻訳
├── middleware.ts            # 認証ミドルウェア（/chat 保護）
└── types/
    └── next-auth.d.ts       # NextAuth 型拡張
```

2.2 状態管理設計

Redux/Zustand は未使用。React hooks + Context API で管理。

ChatPage（chat/page.tsx）の主要 State

State	型	用途
`sessions`	`Session[]`	セッション一覧
`activeSessionId`	`string | null`	選択中のセッション
`messages`	`Message[]`	現在のセッションのメッセージ
`isStreaming`	`boolean`	ストリーミング中フラグ
`selectedModel`	`ModelId`	選択中のモデル
`isDebateMode`	`boolean`	ディベートモード ON/OFF
`isThinkingMode`	`boolean`	拡張思考モード ON/OFF

localStorage キャッシュ

キー	内容	用途
`claudia-sessions`	セッション一覧	初回ロード高速化
`claudia-active-session`	アクティブセッション ID	セッション復元
`claudia-model-{sessionId}`	モデル ID	セッション別モデル選択保持
`claudia-theme`	テーマ名	テーマ永続化
`anthropic-api-key` 等	API キー	BYOK キー保持

Context API

Context	提供値	用途
`SessionProvider` (NextAuth)	`useSession()`	認証状態
`ThemeProvider`	`{ theme, toggleTheme, themeLabel }`	テーマ管理
`NextIntlClientProvider`	翻訳関数	i18n

2.3 コンポーネント詳細

ChatInput

```
送信方法: Cmd+Enter (Mac) / Ctrl+Enter (Win) = 送信
          Enter = 改行

機能:
- テキスト入力（textarea、自動リサイズ）
- 画像添付（クリップボード貼り付け or ファイル選択）
- モデル選択ドロップダウン
- ディベートモード切替
- 拡張思考モード切替
- 画像プレビュー表示
```

QAPairBlock

```
構造:
├── ユーザーメッセージ（質問）
│   ├── テキスト
│   └── 添付画像（サムネイル）
├── アシスタントメッセージ（回答）
│   ├── MessageContent（Markdown レンダリング）
│   ├── DebateDisplay（ディベート時）
│   └── TokenUsageTooltip（トークン/コスト）
└── 折りたたみ/展開ボタン

動作:
- 最新の Q&A ペア以外は自動折りたたみ
- クリックで展開/折りたたみ切替
```

Sidebar

```
構造:
├── 新規チャットボタン
├── 検索バー
├── セッション一覧
│   ├── スター付きセッション（優先表示）
│   └── 通常セッション（更新日時順）
│       ├── タイトル（クリックで選択、ダブルクリックで編集）
│       ├── スターボタン
│       ├── エクスポートボタン
│       └── 削除ボタン
├── 設定エリア
│   ├── API キー設定
│   ├── システムプロンプト設定
│   └── コンテキストメモリ設定
├── テーマ切替ボタン
├── 言語切替ボタン
└── ユーザー情報 + ログアウト
```

2.4 API クライアント（lib/api.ts）

ストリーミング通信

```
async function* streamChat(sessionId, message, model, images?, ...): AsyncGenerator<string>
```

- `fetch` + `ReadableStream` で SSE を受信
- `TextDecoder` でチャンクをデコード
- `<!--STATUS:...-->` はステータス表示に分離
- `<!--USAGE:...-->` はトークン情報として分離
- API キーは `X-API-Key` 等のカスタムヘッダーで送信
- Cookie は `credentials: "include"` で自動付与

2.5 テーマシステム

CSS 変数ベース

```
テーマクラス:
- （なし）      → Dark テーマ
- light-blue  → Sky Blue テーマ
- light-cyan  → Cyan テーマ

html 要素にクラスを付与して切替
```

Tailwind カスタムカラー

用途	Tailwind クラス
背景（ベース）	`bg-theme-base`
背景（サーフェス）	`bg-theme-surface`
背景（入力欄）	`bg-theme-input`
ホバー	`bg-theme-hover`
テキスト（主要）	`text-t-primary`
テキスト（副次）	`text-t-secondary`
ボーダー	`border-border-primary`

2.6 i18n 設計

- **ライブラリ**: next-intl v4
- **ロケール検出**: Cookie → Accept-Language → デフォルト(en)
- **翻訳ファイル**: `messages/en.json`, `messages/ja.json`
- **使用方法**: `useTranslations('namespace')` フック

2.7 認証フロー

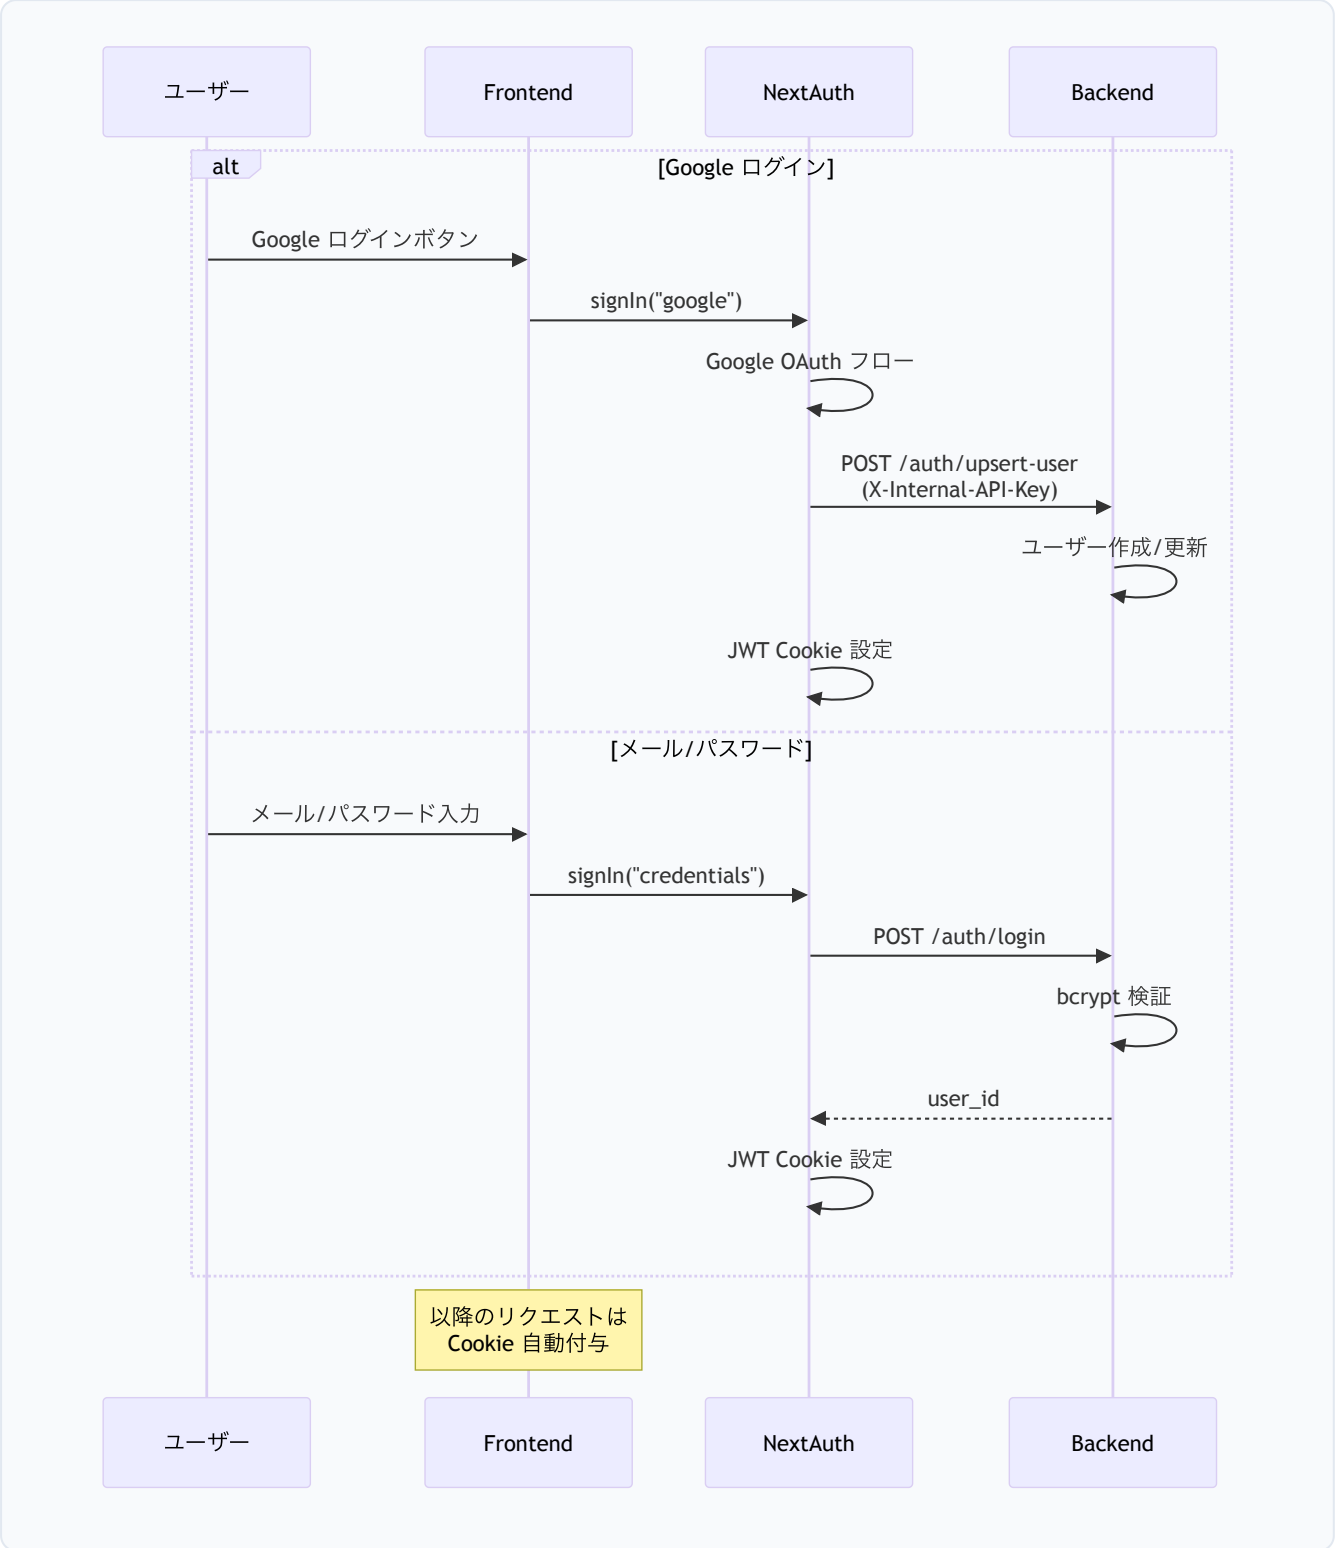
ユーザー
Frontend
NextAuth
Backend
alt
[Google ログイン]
Google ログインボタン
signIn("google")
Google OAuth フロー
POST /auth/upsert-user
(X-Internal-API-Key)
ユーザー作成/更新
JWT Cookie 設定
[メール/パスワード]
メール/パスワード入力
signIn("credentials")
POST /auth/login
bcrypt 検証
user_id
JWT Cookie 設定
以降のリクエストは
Cookie 自動付与
ユーザー
Frontend
NextAuth
Backend

3. データベース詳細設計

3.1 テーブル定義

users テーブル

カラム	型	NULL	デフォルト	制約	説明
id	UUID	NO	uuid4()	PK	ユーザー ID
google_id	VARCHAR	YES	-	UNIQUE	Google OAuth ID
email	VARCHAR	NO	-	UNIQUE	メールアドレス
name	VARCHAR	YES	-	-	表示名
password_hash	VARCHAR	YES	-	-	bcrypt ハッシュ
auth_provider	VARCHAR	NO	-	-	'google' / 'email'
system_prompt	TEXT	YES	-	-	グローバルプロンプト
created_at	TIMESTAMP	NO	utcnow()	-	作成日時

chat_sessions テーブル

カラム	型	NULL	デフォルト	制約	説明
id	UUID	NO	uuid4()	PK	セッション ID
user_id	UUID	NO	-	FK→users.id	所有者
title	VARCHAR(60)	NO	-	-	タイトル
system_prompt	TEXT	YES	-	-	セッション固有プロンプト
is_starred	BOOLEAN	NO	False	-	スター状態
created_at	TIMESTAMP	NO	utcnow()	-	作成日時
updated_at	TIMESTAMP	YES	utcnow()	ON UPDATE	更新日時

messages テーブル

カラム	型	NULL	デフォルト	制約	説明
id	UUID	NO	uuid4()	PK	メッセージ ID
session_id	UUID	NO	-	FK→chat_sessions.id	セッション
role	VARCHAR	NO	-	-	'user' / 'assistant'
content	TEXT	NO	-	-	メッセージ本文
images	JSON	YES	-	-	画像配列 [{media_type, data}]
model	VARCHAR(64)	YES	-	-	使用モデル名
input_tokens	INTEGER	YES	-	-	入力トークン数
output_tokens	INTEGER	YES	-	-	出力トークン数
cost	FLOAT	YES	-	-	コスト (USD)
created_at	TIMESTAMP	NO	utcnow()	INDEX	作成日時

contexts テーブル

カラム	型	NULL	デフォルト	制約	説明
id	UUID	NO	uuid4()	PK	コンテキスト ID
user_id	UUID	NO	-	FK→users.id, INDEX	所有者
content	TEXT	NO	-	-	記憶内容
category	VARCHAR(50)	NO	'general'	-	カテゴリ
source	VARCHAR(10)	NO	'auto'	-	'auto' / 'manual'
session_id	UUID	YES	-	FK→chat_sessions.id	関連セッション
is_active	BOOLEAN	NO	True	-	有効/無効
created_at	TIMESTAMP	NO	utcnow()	-	作成日時
updated_at	TIMESTAMP	YES	utcnow()	ON UPDATE	更新日時

3.2 マイグレーション履歴

順序	リビジョン	内容
1	d8e53b4207ae	初期テーブル作成（users, chat_sessions, messages）
2	a1b2c3d4e5f6	messages に images カラム追加
3	b2c3d4e5f6a7	users, chat_sessions に system_prompt 追加
4	c3d4e5f6a7b8	contexts テーブル作成
5	d405cc65ddce	chat_sessions に updated_at 追加
6	e5f6a7b8c9d0	messages に model 追加
7	f1a2b3c4d5e6	chat_sessions に is_starred 追加
8	g7h8i9j0k1l2	messages に input_tokens, output_tokens, cost 追加
9	h8i9j0k1l2m3	パフォーマンスインデックス追加

4. インフラ詳細設計

4.1 Nginx ルーティング

パス	転送先	設定
`/chat/{UUID}`	Backend :8000	SSE、proxy_buffering off、timeout 600s
`/debate/{UUID}`	Backend :8000	SSE、proxy_buffering off、timeout 600s
`/contexts`	Backend :8000	通常プロキシ
`/sessions`	Backend :8000	通常プロキシ
`/auth/`	Backend :8000	通常プロキシ
`/health`	Backend :8000	ヘルスチェック
`/` (その他)	Frontend :3000	WebSocket 対応（Upgrade ヘッダー）

注意: SSE エンドポイントは UUID 正規表現でマッチし、フロントエンドの `/chat` ページとの衝突を回避。

4.2 systemd サービス構成

```
claudia-backend.service
   ├─── After: network.target, postgresql.service
   ├─── ExecStart: venv/bin/uvicorn backend.main:app --host 127.0.0.1 --port 8000
   ├─── EnvironmentFile: .env
   └─── Restart: always (5秒間隔)

claudia-frontend.service
   ├─── After: network.target, claudia-backend.service
   ├─── ExecStart: next start -p 3000
   ├─── EnvironmentFile: frontend/.env.local
   └─── Restart: always (5秒間隔)
```

4.3 GitHub Actions ワークフロー

本番デプロイ（deploy.yml）

```
トリガー: push to main
認証: Workload Identity Federation
同時実行制御: deploy-gce グループ（全プロジェクト共有）

Steps:
1. GCP 認証
2. SSH で deploy-prod.sh 実行
3. ヘルスチェック（:8000/health）
4. Slack 通知（Mazelan 本番チャンネル）
```

ステージングデプロイ（deploy-staging.yml）

```
トリガー: push to develop
追加処理: DEV バージョン抽出、変更概要抽出

Steps:
1. コードチェックアウト（fetch-depth: 50）
2. DEV バージョン番号抽出
3. マージコミットから変更概要抽出
4. GCP 認証
5. SSH で deploy-staging.sh 実行
6. ヘルスチェック（:8002/health）
7. Slack 通知（バージョン + 変更内容付き）
```

4.4 デプロイスクリプト処理

```
1. git fetch + reset（最新コード取得）
2. venv/bin/pip install -r requirements.txt
3. venv/bin/alembic upgrade head
4. systemctl stop backend + frontend（メモリ確保）
5. npm ci（失敗時 npm install にフォールバック）
6. NODE_OPTIONS="--max_old_space_size=384" npm run build
7. systemctl start backend + frontend
8. 60秒ヘルスチェックループ（2秒間隔）
```

4.5 PostgreSQL チューニング

e2-small (0.5vCPU / 2GB RAM) 向けの軽量設定:

パラメータ	値	理由
shared_buffers	64MB	RAM の約3%
work_mem	4MB	クエリ単位のメモリ
maintenance_work_mem	32MB	VACUUM 等
max_connections	20	小規模 VM 向け
effective_cache_size	256MB	OS キャッシュ見積もり

4.6 SSL / TLS

- Let's Encrypt (certbot) で自動取得・更新
- Nginx 設定は certbot が自動追記（デプロイスクリプトでは上書きしない）
- HSTS 有効（max-age=31536000）

5. 外部サービス連携

5.1 SerpAPI

項目	値
用途	Amazon 商品検索、Google Flights 検索
無料枠	250回/月
キャッシュ	インメモリ TTL（Amazon: 1時間、フライト: 3時間）
フォールバック	エラー時は Web 検索で代替（注意書き付き）
環境変数	`SERPAPI_KEY`

5.2 Travelpayouts

項目	値
用途	航空会社公式サイト URL 生成、Aviasales 価格比較リンク
アフィリエイト ID	508503
環境変数	`TRAVELPAYOUTS_TOKEN`

5.3 Google OAuth

項目	値
用途	Google アカウントでのログイン
環境変数	`GOOGLE_CLIENT_ID`, `GOOGLE_CLIENT_SECRET`

5.4 Slack

項目	値
用途	デプロイ通知
チャンネル	Mazelan 本番 / Mazelan ステージング

6. 環境変数一覧

6.1 バックエンド (.env)

変数	必須	説明
`DATABASE_URL`	✓	PostgreSQL 接続文字列
`SERPAPI_KEY`	-	SerpAPI キー（ツール使用に必要）
`TRAVELPAYOUTS_TOKEN`	-	Travelpayouts トークン
`CLOUDFLARE_API_TOKEN`	-	Cloudflare API トークン

6.2 バックエンド (.env.production)

変数	必須	説明
`DATABASE_URL`	✓	本番 DB 接続文字列
`NEXTAUTH_SECRET`	✓	NextAuth セッション暗号化キー
`CORS_ORIGINS`	✓	許可オリジン
`INTERNAL_API_KEY`	✓	内部 API 認証キー
`ENV`	✓	"production"

6.3 フロントエンド (frontend/.env.production)

変数	必須	説明
`NEXTAUTH_URL`	✓	アプリケーション URL
`NEXTAUTH_SECRET`	✓	NextAuth 暗号化キー
`BACKEND_URL`	✓	バックエンド内部 URL
`NEXT_PUBLIC_BACKEND_URL`	✓	バックエンド公開 URL（ビルド時埋め込み）
`GOOGLE_CLIENT_ID`	✓	Google OAuth クライアント ID
`GOOGLE_CLIENT_SECRET`	✓	Google OAuth シークレット
`INTERNAL_API_KEY`	✓	内部 API 認証キー